Descripción del dataset y origen

Proyecto: Análisis de la afectación de incendios en turberas mediante aprendizaje automático.

Fuente: Aravena Acuña (2026), CONICET Digital – CADIC.

Dimensiones: 231 registros y 15 variables.

Descripción de las variables

Variable	Tipo de dato	Descripción e interpretación
`N`	Entero (`int64`)	Número o índice de registro de la muestra. Se utiliza para identificar cada observación dentro del conjunto de datos.
`Turbera`	Categórica (`object`)	Identificación de la turbera donde se realizó el muestreo. Se registran siete turberas: B1, B3, B8, B9, B11, B21 e I2.
`Transecta`	Categórica (`object`)	Identificación de la transecta correspondiente al sector donde se recolectó la muestra.
`ID_SOBRE`	Entero (`int64`)	Identificador asociado al sobre o recipiente de recolección de la muestra.
`Microtopography`	Categórica (`object`)	Característica de la microtopografía de la turbera. Presenta las categorías HUM (montículo) y HOL (depresión).
`Burn_Severity`	Categórica (`object`)	Nivel de severidad del incendio registrado para cada muestra. Presenta tres categorías: Low (baja), Moderate (moderada) y High (alta). Es la variable objetivo del modelo de clasificación.
`pH`	Decimal (`float64`)	Medida del nivel de acidez o alcalinidad del material de la turbera.
`CE`	Decimal (`float64`)	Conductividad eléctrica. Representa la capacidad del material para conducir corriente eléctrica y aporta información sobre su composición química.

`DOB`	Decimal (`float64`)	Variable fisicoquímica cuyo significado y unidad deben confirmarse con la documentación original o la autora del dataset.
`MO`	Decimal (`float64`)	Contenido de materia orgánica presente en la muestra.
`HD`	Decimal (`float64`)	Variable cuantitativa asociada a una propiedad fisicoquímica del material.
`BD`	Decimal (`float64`)	Densidad aparente (Bulk Density). Representa la masa del material seco por unidad de volumen.
`VWC`	Decimal (`float64`)	Contenido volumétrico de agua (Volumetric Water Content). Expresa la proporción de agua respecto del volumen total de la muestra.
`Ntotal`	Decimal (`float64`)	Contenido de nitrógeno total de la muestra. Presenta únicamente 62 registros válidos de los 231 disponibles.
`GWC`	Decimal (`float64`)	Contenido gravimétrico de agua (Gravimetric Water Content). Representa la cantidad de agua en relación con la masa del material seco.

Categorías de la variable objetivo

La variable `Burn_Severity` será utilizada para entrenar y evaluar un modelo de clasificación multiclase.

Categoría	**Interpretación**	**Cantidad**	**Porcentaje**
Low	Severidad baja	71	30,7 %
Moderate	Severidad moderada	60	26,0 %

High	Severidad alta	100	43,3 %
Total		231	100 %

Las categorías presentan un orden natural de severidad. Sin embargo, inicialmente se abordará el problema mediante clasificadores multiclase convencionales.

Es importante aclarar que la categoría Low representa una severidad baja y no necesariamente una turbera sin afectación por el incendio.

Calidad y disponibilidad de los datos

A continuación se detalla la variable que presenta valores faltantes, el resto están completas..

Variable	Registros disponibles	Valores faltantes	Completitud
Ntotal	62	169	26,8 %

Se observa que `Ntotal` presenta una proporción elevada de valores faltantes (73,2 %), por lo que se eliminó del dataset del análisis principal.

Consideraciones para el modelado

Para evitar problemas metodológicos durante el entrenamiento del modelo se establecen los siguientes criterios:

- Excluir `N` e `ID_SOBRE`, porque funcionan como identificadores.
- No utilizar `Turbera` y `Transecta` como predictoras del modelo principal, aunque pueden servir para analizar la distribución de los errores.
- Eliminar `Ntotal` por su elevada cantidad de valores faltantes.
- Usar RobustScaler para tratar los valores outlaiers.

Fuente y procedencia de los datos

Nombre del dataset: Variables fisico-químicas de turberas después de un incendio forestal.

Autora: Aravena Acuña, Marie Claire Alejandra (2026).

Institución: Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET), CADIC.

Ubicación del estudio: Turberas dominadas por Sphagnum, cercanas a Tolhuin, Tierra del Fuego, Argentina.

Repositorio institucional: CONICET Digital – Dataset original.

Licencia: Creative Commons Atribución–NoComercial–CompartirIgual 2.5 Argentina (CC BY-NC-SA 2.5), según la información que compartiste del registro institucional.

Citación bibliográfica:

Aravena Acuña, Marie Claire Alejandra (2026). Variables fisico-químicas de turberas después de un incendio forestal. Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET). Dataset. http://hdl.handle.net/11336/284253

Organización del proyecto – Cookiecutter

Para mantener una estructura organizada y reproducible, se utilizará la estructura de directorios generada mediante Cookiecutter en el repositorio de GitHub.

Repositorio del proyecto: AA_Afectacion_incendio_en_turbera – GitHub.

Directorio	Contenido
`data/raw/`	Archivo original descargado del repositorio institucional, sin modificaciones.
`data/interim/`	Datos intermedios, luego de las primeras tareas de limpieza y transformación.
`data/processed/`	Dataset final preparado para el entrenamiento y evaluación de los modelos.
`docs/`	Documentación del proyecto, diccionario de datos, descripción de variables y metodología.